

تشخیص جعل گفتار با استفاده از شبکه‌های عصبی عمیق

گزارش آزمایش‌های ASVspoof 2019 LA

ترکیب ۱۳ آزمایش:
۴ استخراج‌کننده ویژگی × ۳ معماری + RawNet2

فهرست مطالب

۳	۱ مقدمه
۳	۱.۱ پیشینه
۴	۲.۱ اهداف آزمایش
۵	۲ داده و پیش‌پردازش
۵	۱.۲ مجموعه داده ASVspoof 2019 LA
۵	۲.۲ خط لوله پیش‌پردازش
۷	۳ استخراج ویژگی
۷	۱.۳ MFCC – ضرایب کپستراال فرکانس ملی
۷	۲.۳ LFCC – ضرایب کپستراال فرکانس خطی
۸	۳.۳ CQCC – ضرایب کپستراال تبدیل Q ثابت
۸	۴.۳ SincConv – فیلتربانک یادگیرنده
۹	۴ معماری‌های شبکه عصبی
۹	۱.۴ CNN – شبکه کانولوشنی پایه
۹	۲.۴ Res2Net – شبکه با اتصالات باقیمانده چندمقیاسی
۱۰	۳.۴ LCNN – شبکه با واحد حداکثر درصدی
۱۰	۴.۴ RawNet2 – شبکه روی موج خام
۱۱	۵ آموزش و ارزیابی
۱۱	۱.۵ تنظیمات آموزش
۱۱	۲.۵ مولد داده
۱۱	۳.۵ شروع مجدد آزمایش
۱۲	۶ نتایج
۱۲	۱.۶ جدول مقایسه‌ای
۱۳	۲.۶ بهترین سیستم

۳.۶	نمودار مقایسه‌ای	۱۳
۴.۶	منحنی‌های آموزش	۱۳

۷ بحث و نتیجه‌گیری ۱۴

۱.۷	تحلیل ویژگی‌ها	۱۴
۲.۷	تحلیل معماری‌ها	۱۴
۳.۷	نتیجه‌گیری	۱۴

فصل ۱

مقدمه

۱.۱ پیشینه

تشخیص جعل گفتار (Spoofing Detection) یکی از چالش‌های اساسی در سیستم‌های تأیید هویت گوینده (Speaker Verification) است. مجموعه داده ASVspoof 2019 LA یک محک استاندارد برای ارزیابی سیستم‌های مقابله با جعل (Countermeasure, CM) فراهم می‌کند.

تعریف ۱.۱ ▷ جعل گفتار

جعل گفتار به تولید یا تبدیل گفتار به گونه‌ای گفته می‌شود که سیستم تأیید هویت را فریب دهد. در مجموعه LA، حمله‌ها از طریق سنتز متن به گفتار (TTS) و تبدیل صدا (VC) انجام می‌شوند.

تعریف ۲.۱ ▷ معیار ارزیابی EER

نرخ خطای برابر (Equal Error Rate, EER) نقطه‌ای است که در آن نرخ پذیرش اشتباه (FAR) و نرخ رد اشتباه (FRR) برابرند. مقدار کمتر بهتر است.

تعریف ۳.۱ ▷ معیار min-tDCF

هزینه تشخیص کمینه‌شده (min-tDCF) معیار رسمی ASVspoof است که هزینه‌های جاخوردن و پذیرش اشتباه را با احتمال پیشین جعل ترکیب می‌کند.

$$tDCF = C_{\text{miss}} \cdot P_{\text{spoof}} \cdot P_{\text{miss}} + C_{\text{fa}} \cdot (1 - P_{\text{spoof}}) \cdot P_{\text{fa}}$$

۲.۱ اهداف آزمایش

هدف اصلی مقایسه سیستماتیک ترکیب‌های مختلف استخراج ویژگی و معماری شبکه عصبی در چارچوب ASVspoof 2019 LA است. ۱۳ آزمایش به شرح جدول ۱.۱ اجرا می‌شوند.

جدول ۱.۱: ترکیب‌های آزمایشی

#	ویژگی	مدل	توضیح
۱	MFCC	CNN	ضرایب کپسترتال فرکانس ملی + CNN
۲	MFCC	Res2Net	ضرایب کپسترتال فرکانس ملی + Res2Net
۳	MFCC	LCNN	ضرایب کپسترتال فرکانس ملی + LCNN
۴	LFCC	CNN	ضرایب کپسترتال فرکانس خطی + CNN
۵	LFCC	Res2Net	ضرایب کپسترتال فرکانس خطی + Res2Net
۶	LFCC	LCNN	ضرایب کپسترتال فرکانس خطی + LCNN
۷	CQCC	CNN	ضرایب کپسترتال تبدیل CQ + CNN
۸	CQCC	Res2Net	ضرایب کپسترتال تبدیل CQ + Res2Net
۹	CQCC	LCNN	ضرایب کپسترتال تبدیل CQ + LCNN
۱۰	SincConv	CNN	فیلتربانک یادگیرنده + CNN
۱۱	SincConv	Res2Net	فیلتربانک یادگیرنده + Res2Net
۱۲	SincConv	LCNN	فیلتربانک یادگیرنده + LCNN
۱۳	موج خام	RawNet2	پردازش مستقیم موج صوتی

فصل ۲

داده و پیش‌پردازش

۱.۲ مجموعه داده ASVspoof 2019 LA

مشخصات مجموعه داده

- نرخ نمونه‌برداری: 16000 Hz
- مدت ثابت پس از برش: ۴ ثانیه (64000 نمونه)
- پروتکل‌ها: train / dev / eval
- برچسب‌ها: bonafide (واقعی، ۰) و spoof (جعلی، ۱)

نتیجه > آمار مجموعه داده

[جدول توزیع نمونه‌های واقعی و جعلی برای هر بخش (train/dev/eval) اینجا قرار می‌گیرد].
[مثال: Train: X نمونه | Dev: Y نمونه | Eval: Z نمونه]

۲.۲ خط لوله پیش‌پردازش

روش ۱.۲ > پیش‌پردازش استاندارد

- پیش‌پردازش اجباری برای همه آزمایش‌ها:
۱. بارگذاری: librosa.load با sr=16000
 ۲. نرمال‌سازی دامنه: $x \leftarrow x / (\max |x| + \epsilon)$
 ۳. برش/تکرار: تنظیم طول به دقیقاً ۶۴۰۰۰ نمونه

روش ۲.۲ > پیش‌پردازش اختیاری

پرچم‌های قابل فعال‌سازی در پیکربندی:

`USE_VAD` حذف سکوت ابتدا/انتهای فایل (`librosa.effects.trim`)

`USE_RAWBOOST` افزوده‌سازی با نویز گاوسی و ضربه‌ای تصادفی (با احتمال ۵۰٪ در آموزش)

`USE_REVERB` شبیه‌سازی بازتاب ساده با تأخیر تصادفی (با احتمال ۳۰٪ در آموزش)

`USE_DENOISING` کاهش نویز با آستانه‌گذاری طیفی

یادداشت

در آزمایش‌های این گزارش، `USE_VAD` و `USE_RAWBOOST` فعال هستند؛ `USE_REVERB` و `USE_DENOISING` غیرفعالند.

فصل ۳

استخراج ویژگی

۱.۳ MFCC – ضرایب کپسترال فرکانس ملی

تعریف ۱.۳ MFCC

ضرایب کپسترال مقیاس ملی (Mel-Frequency Cepstral Coefficients) از اعمال DCT روی لگاریتم انرژی فیلتربانک ملی به دست می‌آیند. شکل خروجی: $(N_{frames}, 60, 1)$

پارامترهای کلیدی:

- پنجره: 400 نمونه، پیشروی: 160 نمونه، FFT: ۵۱۲ نقطه
- تعداد ضرایب: $N_{MFCC} = 60$

۲.۳ LFCC – ضرایب کپسترال فرکانس خطی

تعریف ۲.۳ LFCC

مشابه MFCC اما فیلتربانک روی مقیاس **خطی** فرکانس تعریف می‌شود (نه ملی)، که اطلاعات فرکانس بالا را بهتر حفظ می‌کند. شکل خروجی: $(N_{frames}, 60, 1)$

۳.۳ CQCC – ضرایب کپسترال تبدیل Q ثابت

تعریف ۳.۳ ▷ CQCC

تبدیل Q ثابت (CQT) رزولوشن زمان-فرکانس لگاریتمی دارد که برای تجزیه و تحلیل گفتار مناسب تر از STFT است. پس از CQT، DCT اعمال می شود. شکل خروجی: $(N_{\text{frames}}, 60, 1)$

پارامترها: ۹۶ باند، ۲۴ باند در هر اکتاو، پایین ترین فرکانس: 32.7 Hz C1.

۴.۳ SincConv – فیلتربانک یادگیرنده

تعریف ۴.۳ ▷ SincConv1D

لایه کانولوشنی با هسته های sinc پارامتری شده. هر فیلتر یک باندگذر تعریف می کند که مرزهای پایین (f_1) و بالا (f_2) آن در طول آموزش یاد گرفته می شوند:

$$h[n] = 2f_2 \text{sinc}(2\pi f_2 n) - 2f_1 \text{sinc}(2\pi f_1 n)$$

مقداردهی اولیه بر اساس مقیاس ملی انجام می شود.

یادداشت

ورودی SincConv موج خام است، اما خروجی آن به صورت نقشه ویژگی دوبعدی $(N_{\text{frames}}, N_{\text{filters}}, 1)$ وارد معماری های CNN، Res2Net یا LCNN می شود.

فصل ۴

معماری‌های شبکه عصبی

۱.۴ CNN – شبکه کانولوشنی پایه

روش ۱.۴ ▷ معماری CNN

چهار بلوک متوالی هر کدام شامل:

۱. دو لایه Conv2D با فیلترهای $\{32, 64, 128, 256\}$ ، هسته 3×3
۲. ReLU + BatchNorm
۳. (2×2) MaxPool2D + Dropout (۱.۰)

در پایان: GlobalAvgPool Dense (۱۲۸) Dropout (۳.۰) Sigmoid

۲.۴ Res2Net – شبکه با اتصالات باقیمانده چندمقیاسی

روش ۲.۴ ▷ معماری Res2Net

بلوک Res2Net ویژگی‌های کانال را به $s = 4$ گروه تقسیم می‌کند و اتصالات هرمی بین گروه‌ها ایجاد می‌کند. همچنین بلوک SE (Squeeze-and-Excitation) برای توجه کانالی استفاده می‌شود.

- ابعاد: (7×7) Conv2D بلوک‌های Res2Net با $\{64, 128, 256\}$ فیلتر
- SE Block: نسبت $r = 8$ ، sigmoid گیت

۳.۴ LCNN – شبکه با واحد حداکثر درصدی

تعریف ۱.۴ ▷ واحد MFM

واحد حداکثر درصدی (Max-Feature-Map, MFM) خروجی لایه را به دو نیمه تقسیم کرده و به صورت عنصر به عنصر بیشینه می‌گیرد:

$$\text{MFM}(x) = \max(x_{:c}, x_c)$$

این عملیات نقش فعال‌سازی و کاهش ابعاد را همزمان ایفا می‌کند.

روش ۳.۴ ▷ معماری LCNN

پنج بلوک BN+MFM+Conv2D با پولینگ متناوب. ابعاد کانال: $128 \rightarrow 128 \rightarrow 128 \rightarrow 64 \rightarrow 64$ (قبل از MFM). در انتها: GlobalAvgPool (MFM از (256)Dense Sigmoid (128)Dense

۴.۴ RawNet2 – شبکه روی موج خام

روش ۴.۴ ▷ معماری RawNet2

تنها مدلی که مستقیم روی موج صوتی کار می‌کند:

۱. $\text{SincConv1D}(128)$ (فیلتر، هسته ۱۰۲۵) + BN + $\text{MaxPool1D}(3)$

۲. دو بلوک $\text{Res1D}(128)$ + $\text{MaxPool1D}(3)$

۳. دو بلوک $\text{Res1D}(256)$ + $\text{MaxPool1D}(3)$

۴. دو بلوک $\text{Res1D}(512)$ + $\text{MaxPool1D}(3)$

۵. $\text{GRU}(1024)$ Dense (1024) Sigmoid

یادداشت

RawNet2 از همان لایه SincConv1D استفاده می‌کند، اما در اینجا فیلتربانک بخشی از معماری کلی است و نه یک مرحله پیش‌پردازش مجزا.

فصل ۵

آموزش و ارزیابی

۱.۵ تنظیمات آموزش

بیکربندی آموزش

- بهینه‌ساز: Adam با نرخ یادگیری اولیه 10^{-4}
- تابع خطا: Binary Crossentropy
- اندازه دسته: ۳۲
- حداکثر دوره: ۳۰
- توقف زودهنگام: صبر ۷ دوره، بر اساس `val_loss`
- کاهش نرخ یادگیری: در صورت عدم بهبود ۳ دوره، ضرب در 5.0×10^{-6} (کمینه 10^{-6})
- ذخیره بهترین وزن: بر اساس کمترین `val_loss`

۲.۵ مولد داده

کلاس `ASVDataset` یک `Keras Sequence` است که بارگذاری، پیش‌پردازش و استخراج ویژگی را همزمان انجام می‌دهد تا از مشکل حافظه جلوگیری شود. برای ورودی‌های دوبعدی (مانند MFCC) شکل دسته $(B, N_f, N_c, 1)$ و برای ورودی خام شکل $(B, N_s, 1)$ است.

۳.۵ شروع مجدد آزمایش

نتایج هر آزمایش بلافاصله پس از اتمام در `results_partial.csv` ذخیره می‌شود. در صورت وقفه، آزمایش‌های تکمیل‌شده از قبل رد می‌شوند.

فصل ۶

نتایج

۱.۶ جدول مقایسه‌ای

نتیجه ▷ جدول نتایج کامل

[جدول زیر پس از اجرای تمام آزمایش‌ها تکمیل می‌شود.]

جدول ۱.۶: نتایج همه آزمایش‌ها

Eval tDCF	Dev tDCF	%Eval EER	%Dev EER	مدل	ویژگی	آزمایش
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	CNN	MFCC	mfcc_cnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	Res2Net	MFCC	mfcc_res2net
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	LCNN	MFCC	mfcc_lcnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	CNN	LFCC	lfcc_cnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	Res2Net	LFCC	lfcc_res2net
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	LCNN	LFCC	lfcc_lcnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	CNN	CQCC	cqcc_cnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	Res2Net	CQCC	cqcc_res2net
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	LCNN	CQCC	cqcc_lcnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	CNN	Sinc	sinconv_cnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	Res2Net	Sinc	sinconv_res2net
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	LCNN	Sinc	sinconv_lcnn
[X.XXXX]	[X.XXXX]	[XX.XX]	[XX.XX]	RawNet2	موج خام	raw_rawnet2

۲.۶ بهترین سیستم

نتیجه ▷ بهترین ترکیب

[بهترین آزمایش بر اساس $Eval\ EER$]
[آزمایش: نام] | $XX.XX\% EER$ | $X.XXXX\ min-tDCF$

۳.۶ نمودار مقایسه‌ای

نتیجه ▷ نمودار EER

[تصویر $results_comparison.png$ اینجا قرار می‌گیرد.]
`[\includegraphics[width=\textwidth]{results/results\_comparison.png}]`

۴.۶ منحنی‌های آموزش

نتیجه ▷ منحنی خطا و دقت

[تصاویر $_curve.png$ برای هر آزمایش اینجا قرار می‌گیرند.]

فصل ۷

بحث و نتیجه‌گیری

۱.۷ تحلیل ویژگی‌ها

نتیجه ▷ مقایسه ویژگی‌ها

[پس از دریافت نتایج، مقایسه MFCC/LFCC/CQCC/SincConv از نظر EER و tDCF اینجا نوشته می‌شود.]

۲.۷ تحلیل معماری‌ها

نتیجه ▷ مقایسه معماری‌ها

[پس از دریافت نتایج، مقایسه ۲Net/LCNN/RawNet۲CNN/Res اینجا نوشته می‌شود.]

۳.۷ نتیجه‌گیری

گزاره ۱.۷ ▷ نتیجه کلی

[نتیجه‌گیری نهایی پس از تکمیل آزمایش‌ها درج می‌شود.]