

تشخیص جعل گفتار با استفاده از شبکه‌های عصبی عمیق

گزارش آزمایش‌های ASVspoof 2019 LA

ترکیب ۱۱ آزمایش موفق از ۱۳ طرح:
۴ استخراج‌کننده ویژگی $\times$ ۳ معماری RawNet2 +

فهرست مطالب

۳	۱ مقدمه
۳	۱.۱ پیشینه
۴	۲.۱ اهداف آزمایش
۵	۲ داده و پیش‌پردازش
۵	۱.۲ مجموعه داده ASVspoof 2019 LA
۶	۲.۲ خط لوله پیش‌پردازش
۷	۳ استخراج ویژگی
۷	۱.۳ MFCC – ضرایب کپسترال فرکانس ملی
۷	۲.۳ LFCC – ضرایب کپسترال فرکانس خطی
۸	۳.۳ CQCC – ضرایب کپسترال تبدیل Q ثابت
۸	۴.۳ SincConv – فیلتربانک یادگیرنده
۹	۴ معماری‌های شبکه عصبی
۹	۱.۴ CNN – شبکه کانولوشنی پایه
۹	۲.۴ Res2Net – شبکه با اتصالات باقیمانده چندمقیاسی
۱۰	۳.۴ LCNN – شبکه با واحد حداکثر درصدی
۱۰	۴.۴ RawNet2 – شبکه روی موج خام
۱۱	۵ آموزش و ارزیابی
۱۱	۱.۵ تنظیمات آموزش
۱۱	۲.۵ مولد داده
۱۱	۳.۵ شروع مجدد آزمایش
۱۲	۶ نتایج
۱۲	۱.۶ جدول مقایسه‌ای
۱۳	۲.۶ بهترین سیستم

۳.۶	نمودار مقایسه‌ای	۱۳
۴.۶	منحنی‌های آموزش	۱۳

۷ بحث و نتیجه‌گیری ۱۶

۱.۷	تحلیل ویژگی‌ها	۱۶
۲.۷	تحلیل معماری‌ها	۱۶
۳.۷	نتیجه‌گیری	۱۷

فصل ۱

مقدمه

۱.۱ پیشینه

تشخیص جعل گفتار (Spoofing Detection) یکی از چالش‌های اساسی در سیستم‌های تأیید هویت گوینده (Speaker Verification) است. مجموعه داده ASVspoof 2019 LA یک محک استاندارد برای ارزیابی سیستم‌های مقابله با جعل (Countermeasure, CM) فراهم می‌کند.

تعریف ۱.۱ ▷ جعل گفتار

جعل گفتار به تولید یا تبدیل گفتار به گونه‌ای گفته می‌شود که سیستم تأیید هویت را فریب دهد. در مجموعه LA، حمله‌ها از طریق سنتز متن به گفتار (TTS) و تبدیل صدا (VC) انجام می‌شوند.

تعریف ۲.۱ ▷ معیار ارزیابی EER

نرخ خطای برابر (Equal Error Rate, EER) نقطه‌ای است که در آن نرخ پذیرش اشتباه (FAR) و نرخ رد اشتباه (FRR) برابرند. مقدار کمتر بهتر است.

تعریف ۳.۱ ▷ معیار min-tDCF

هزینه تشخیص کمینه‌شده (min-tDCF) معیار رسمی ASVspoof است که هزینه‌های جاخوردن و پذیرش اشتباه را با احتمال پیشین جعل ترکیب می‌کند.

$$tDCF = C_{miss} \cdot P_{spoof} \cdot P_{miss} + C_{fa} \cdot (1 - P_{spoof}) \cdot P_{fa}$$

۲.۱ اهداف آزمایش

هدف اصلی مقایسه سیستماتیک ترکیب‌های مختلف استخراج ویژگی و معماری شبکه عصبی در چارچوب ASVspoof 2019 LA است. ۱۳ آزمایش به شرح جدول ۱.۱ اجرا می‌شوند.

جدول ۱.۱: ترکیب‌های آزمایشی

#	ویژگی	مدل	توضیح
۱	MFCC	CNN	ضرایب کپسترتال فرکانس ملی + CNN
۲	MFCC	Res2Net	ضرایب کپسترتال فرکانس ملی + Res2Net
۳	MFCC	LCNN	ضرایب کپسترتال فرکانس ملی + LCNN
۴	LFCC	CNN	ضرایب کپسترتال فرکانس خطی + CNN
۵	LFCC	Res2Net	ضرایب کپسترتال فرکانس خطی + Res2Net
۶	LFCC	LCNN	ضرایب کپسترتال فرکانس خطی + LCNN
۷	CQCC	CNN	ضرایب کپسترتال تبدیل CQ + CNN
۸	CQCC	Res2Net	ضرایب کپسترتال تبدیل CQ + Res2Net
۹	CQCC	LCNN	ضرایب کپسترتال تبدیل CQ + LCNN
۱۰	SincConv	CNN	فیلتربانک یادگیرنده + CNN
۱۱	SincConv	Res2Net	فیلتربانک یادگیرنده + Res2Net
۱۲	SincConv	LCNN	فیلتربانک یادگیرنده + LCNN
۱۳	موج خام	RawNet2	پردازش مستقیم موج صوتی

فصل ۲

داده و پیش‌پردازش

۱.۲ مجموعه داده ASVspoof 2019 LA

مشخصات مجموعه داده

- نرخ نمونه‌برداری: 16000 Hz
- مدت ثابت پس از برش: ۴ ثانیه (64000 نمونه)
- پروتکل‌ها: train / dev / eval
- برچسب‌ها: bonafide (واقعی، ۰) و spoof (جعلی، ۱)

جدول ۱.۲: توزیع نمونه‌ها در مجموعه ASVspoof 2019 LA

بخش	واقعی	جعلی	مجموع
Train	۲۵۸۰	۲۲۸۰۰	۲۵۳۸۰
Dev	۲۵۴۸	۲۲۲۹۶	۲۴۸۴۴
Eval	۷۳۵۵	۶۳۸۸۲	۷۱۲۳۷

۲.۲ خط لوله پیش‌پردازش

روش ۱.۲ > پیش‌پردازش استاندارد

پیش‌پردازش اجباری برای همه آزمایش‌ها:

۱. بارگذاری: librosa.load با $sr=16000$

۲. نرمال‌سازی دامنه: $x \leftarrow x / (\max |x| + \epsilon)$

۳. برش/تکرار: تنظیم طول به دقیقاً ۶۴۰۰۰ نمونه

روش ۲.۲ > پیش‌پردازش اختیاری

پرچم‌های قابل فعال‌سازی در پیکربندی:

USE_VAD حذف سکوت ابتدا/انتهای فایل (librosa.effects.trim)

USE_RAWBOOST افزوده‌سازی با نویز گاوسی و ضربه‌ای تصادفی (با احتمال ۵۰٪ در آموزش)

USE_REVERB شبیه‌سازی بازتاب ساده با تأخیر تصادفی (با احتمال ۳۰٪ در آموزش)

USE_DENOISING کاهش نویز با آستانه‌گذاری طیفی

یادداشت

در آزمایش‌های این گزارش، USE_VAD و USE_RAWBOOST فعال هستند؛ USE_REVERB و USE_DENOISING غیرفعالند.

فصل ۳

استخراج ویژگی

۱.۳ MFCC – ضرایب کپسترال فرکانس ملی

تعریف ۱.۳ MFCC

ضرایب کپسترال مقیاس ملی (Mel-Frequency Cepstral Coefficients) از اعمال DCT روی لگاریتم انرژی فیلتربانک ملی به دست می‌آیند. شکل خروجی: $(N_{frames}, 60, 1)$

پارامترهای کلیدی:

- پنجره: 400 نمونه، پیشروی: 160 نمونه، FFT: ۵۱۲ نقطه
- تعداد ضرایب: $N_{MFCC} = 60$

۲.۳ LFCC – ضرایب کپسترال فرکانس خطی

تعریف ۲.۳ LFCC

مشابه MFCC اما فیلتربانک روی مقیاس **خطی** فرکانس تعریف می‌شود (نه ملی)، که اطلاعات فرکانس بالا را بهتر حفظ می‌کند. شکل خروجی: $(N_{frames}, 60, 1)$

۳.۳ CQCC – ضرایب کپسترا ل تبدیل Q ثابت

تعریف ۳.۳ ▷ CQCC

تبدیل Q ثابت (CQT) رزولوشن زمان-فرکانس لگاریتمی دارد که برای تجزیه و تحلیل گفتار مناسب تر از STFT است. پس از CQT، DCT اعمال می شود. شکل خروجی: $(N_{frames}, 60, 1)$

پارامترها: ۹۶ باند، ۲۴ باند در هر اکتاو، پایین ترین فرکانس: 32.7 Hz C1.

۴.۳ SincConv – فیلتربانک یادگیرنده

تعریف ۴.۳ ▷ SincConv1D

لایه کانولوشنی با هسته های sinc پارامتری شده. هر فیلتر یک باندگذر تعریف می کند که مرزهای پایین (f_1) و بالا (f_2) آن در طول آموزش یاد گرفته می شوند:

$$h[n] = 2f_2 \text{sinc}(2\pi f_2 n) - 2f_1 \text{sinc}(2\pi f_1 n)$$

مقداردهی اولیه بر اساس مقیاس ملی انجام می شود.

یادداشت

ورودی SincConv موج خام است، اما خروجی آن به صورت نقشه ویژگی دوبعدی $(N_{frames}, N_{filters}, 1)$ وارد معماری های CNN، Res2Net یا LCNN می شود.

فصل ۴

معماری‌های شبکه عصبی

۱.۴ CNN – شبکه کانولوشنی پایه

روش ۱.۴ ▷ معماری CNN

چهار بلوک متوالی هر کدام شامل:

۱. دو لایه Conv2D با فیلترهای $\{32, 64, 128, 256\}$ ، هسته 3×3
۲. ReLU + BatchNorm
۳. (2×2) MaxPool2D + Dropout (۱.۰)

در پایان: GlobalAvgPool Dense (۱۲۸) Dropout (۳.۰) Sigmoid

۲.۴ Res2Net – شبکه با اتصالات باقیمانده چندمقیاسی

روش ۲.۴ ▷ معماری Res2Net

بلوک Res2Net ویژگی‌های کانال را به $s = 4$ گروه تقسیم می‌کند و اتصالات هرمی بین گروه‌ها ایجاد می‌کند. همچنین بلوک SE (Squeeze-and-Excitation) برای توجه کانالی استفاده می‌شود.

- ابعاد: (7×7) Conv2D بلوک‌های Res2Net با $\{64, 128, 256\}$ فیلتر
- SE Block: نسبت $r = 8$ ، sigmoid گیت

۳.۴ LCNN – شبکه با واحد حداکثر درصدی

تعریف ۱.۴ ▷ واحد MFM

واحد حداکثر درصدی (Max-Feature-Map, MFM) خروجی لایه را به دو نیمه تقسیم کرده و به صورت عنصر به عنصر بیشینه می‌گیرد:

$$\text{MFM}(x) = \max(x_{:c}, x_c)$$

این عملیات نقش فعال‌سازی و کاهش ابعاد را همزمان ایفا می‌کند.

روش ۳.۴ ▷ معماری LCNN

پنج بلوک BN+MFM+Conv2D با پولینگ متناوب. ابعاد کانال: $128 \rightarrow 128 \rightarrow 128 \rightarrow 64 \rightarrow 64$ (قبل از MFM). در انتها: GlobalAvgPool (MFM از (256)Dense Sigmoid (128)Dense

۴.۴ RawNet2 – شبکه روی موج خام

روش ۴.۴ ▷ معماری RawNet2

تنها مدلی که مستقیم روی موج صوتی کار می‌کند:

۱. $\text{SincConv1D}(128)$ (فیلتر، هسته ۱۰۲۵) + BN + $\text{MaxPool1D}(3)$

۲. دو بلوک $\text{Res1D}(128)$ + $\text{MaxPool1D}(3)$

۳. دو بلوک $\text{Res1D}(256)$ + $\text{MaxPool1D}(3)$

۴. دو بلوک $\text{Res1D}(512)$ + $\text{MaxPool1D}(3)$

۵. $\text{GRU}(1024)$ Dense (1024) Sigmoid

یادداشت

RawNet2 از همان لایه SincConv1D استفاده می‌کند، اما در اینجا فیلتربانک بخشی از معماری کلی است و نه یک مرحله پیش‌پردازش مجزا.

فصل ۵

آموزش و ارزیابی

۱.۵ تنظیمات آموزش

بیکربندی آموزش

- بهینه‌ساز: Adam با نرخ یادگیری اولیه 10^{-4}
- تابع خطا: Binary Crossentropy
- اندازه دسته: ۳۲
- حداکثر دوره: ۳۰
- توقف زودهنگام: صبر ۷ دوره، بر اساس `val_loss`
- کاهش نرخ یادگیری: در صورت عدم بهبود ۳ دوره، ضرب در ۵.۰ (کمینه 10^{-6})
- ذخیره بهترین وزن: بر اساس کمترین `val_loss`

۲.۵ مولد داده

کلاس `ASVDataset` یک `Keras Sequence` است که بارگذاری، پیش‌پردازش و استخراج ویژگی را همزمان انجام می‌دهد تا از مشکل حافظه جلوگیری شود. برای ورودی‌های دوبعدی (مانند MFCC) شکل دسته $(B, N_f, N_c, 1)$ و برای ورودی خام شکل $(B, N_s, 1)$ است.

۳.۵ شروع مجدد آزمایش

نتایج هر آزمایش بلافاصله پس از اتمام در `results_partial.csv` ذخیره می‌شود. در صورت وقفه، آزمایش‌های تکمیل‌شده از قبل رد می‌شوند.

فصل ۶

نتایج

۱.۶ جدول مقایسه‌ای

از ۱۳ آزمایش طراحی شده، ۱۱ آزمایش با موفقیت تکمیل شدند. آزمایش‌های cqcc_res2net و cqcc_lcnن به دلیل ناسازگاری ابعاد خروجی CQCC با معماری‌های Res2Net و LCNN حذف شدند.

جدول ۱.۶: نتایج همه آزمایش‌ها

آزمایش	ویژگی	مدل	%Dev EER	%Eval EER	Dev tDCF	Eval tDCF
mfcc_cnn	MFCC	CNN	۰۹.۸	۸۷.۲۳	۰۰۸۱.۰	۰۰۵۵.۰
mfcc_res2net	MFCC	Res2Net	۹۳.۷	۲۱.۲۳	۰۳۵۲.۰	۰۲۴۷.۰
mfcc_lcnن	MFCC	LCNN	۰۹.۴	۶۰.۲۳	۰۰۷۶.۰	۰۰۵۶.۰
lfcc_cnn	LFCC	CNN	۰۸.۱	۶۳.۱۸	۲۴۸۴.۰	۱۱۴۳.۰
lfcc_res2net	LFCC	Res2Net	۹۰.۰	۹۸.۲۰	۰۰۵۷.۰	۰۰۸۸.۰
lfcc_lcnن	LFCC	LCNN	۵۰.۰	۳۹.۱۶	۱۰۳۱.۰	۰۳۱۱.۰
cqcc_cnn	CQCC	CNN	۳۴.۹	۸۲.۲۶	۰۱۶۶.۰	۰۲۳۸.۰
cqcc_res2net	CQCC	Res2Net		حذف شده		
cqcc_lcnن	CQCC	LCNN		حذف شده		
sinconv_cnn	Sinc	CNN	۲۹.۱۳	۰۸.۳۳	۰۰۵۴.۰	۰۰۵۳.۰
sinconv_res2net	Sinc	Res2Net	۰۳.۱۷	۱۲.۳۴	۰۰۵۴.۰	۰۰۵۳.۰
sinconv_lcnن	Sinc	LCNN	۱۴.۹	۴۵.۲۹	۰۰۷۳.۰	۰۰۶۹.۰
raw_rawnet2	موج خام	RawNet2	۵۳.۹	۸۶.۲۷	۰۰۵۳.۰	۰۰۵۳.۰

۲.۶ بهترین سیستم

بهترین ترکیب بر اساس Eval EER

- آزمایش: lfcc_lcn
- ویژگی: LFCC مدل: LCNN
- Eval EER: ۱۶٫۳۹٪ Dev EER: ۰٫۵۰٪
- Eval min-tDCF: ۰٫۳۱٪ Dev min-tDCF: ۰٫۱۰۳۱٪

یادداشت


اختلاف زیاد بین Eval EER و Dev EER (بیش از ۳۰ برابر) نشان‌دهنده بیش‌برازش شدید به مجموعه توسعه است. این الگو در تمام آزمایش‌ها مشاهده می‌شود و احتمالاً ناشی از تنوع بالاتر حمله‌ها در مجموعه ارزیابی (A19–A07 در مقابل A06–A01) و تعداد محدود دوره‌های آموزش (۸ دوره) است.

۳.۶ نمودار مقایسه‌ای


شکل ۱.۶ مقایسه Eval EER تمام آزمایش‌های موفق را نشان می‌دهد.

۴.۶ منحنی‌های آموزش


منحنی‌های خطا و دقت آموزش برای هر آزمایش در شکل‌های ۲.۶ تا ۶.۶ آورده شده‌اند.




شکل ۱.۶: مقایسه Eval EER آزمایش‌ها – مقدار کمتر بهتر است




شکل ۲.۶: منحنی‌های آموزش ترکیب‌های MFCC




شکل ۳.۶: منحنی‌های آموزش ترکیب‌های LFCC



شکل ۴.۶: منحنی آموزش CQCC+CNN



شکل ۵.۶: منحنی‌های آموزش ترکیب‌های SincConv



شکل ۶.۶: منحنی آموزش RawNet2

فصل ۷

بحث و نتیجه‌گیری

۱.۷ تحلیل ویژگی‌ها

جدول ۱.۷: میانگین Eval EER به تفکیک ویژگی			
ویژگی	میانگین Eval EER %	تعداد آزمایش	
LFCC	۶۷.۱۸	۳	
MFCC	۵۶.۲۳	۳	
CQCC	۸۲.۲۶	۱	
Raw	۸۶.۲۷	۱	
SincConv	۲۲.۳۲	۳	

LFCC بهترین عملکرد را در میان ویژگی‌ها دارد. فیلتربانک خطی اطلاعات فرکانس بالا را بهتر از مقیاس ملی (MFCC) حفظ می‌کند و این اطلاعات برای تشخیص مصنوعات ناشی از سنتز گفتار حیاتی هستند. MFCC در رتبه دوم قرار دارد. CQCC با وجود رزولوشن لگاریتمی مناسب، تنها با CNN آزمایش شد و نتایج ضعیف‌تری داشت.

SincConv ضعیف‌ترین عملکرد را نشان داد. فیلتربانک یادگیرنده با ۸ دوره آموزش فرصت کافی برای تنظیم پارامترهای فیلتر ندارد و به دوره‌های بیشتری نیاز دارد.

۲.۷ تحلیل معماری‌ها

LCNN با واحد MFM بهترین عملکرد متوسط را دارد. عملیات حداکثر ویژگی‌نگاره نقش انتخاب ویژگی ضمنی را ایفا کرده و به مدل کمک می‌کند ویژگی‌های تمایزکننده‌تر را حفظ کند.

جدول ۲.۷: میانگین Eval EER به تفکیک معماری (فقط ویژگی‌های مشترک)

معماری	میانگین Eval EER %	توضیح
LCNN	۱۴.۲۳	بهترین عملکرد متوسط
CNN	۱۹.۲۵	ساده‌ترین معماری
Res2Net	۱۱.۲۶	پیچیده‌ترین معماری
RawNet2	۸۶.۲۷	فقط ورودی خام

CNN با وجود سادگی، عملکرد رقابتی دارد. Res2Net با وجود اتصالات باقیمانده چندمقیاسی و بلوک SE، بهبود مشخصی نسبت به CNN ایجاد نکرد. این نشان می‌دهد که پیچیدگی بیشتر معماری لزوماً به عملکرد بهتر منجر نمی‌شود، به‌ویژه با تعداد دوره‌های محدود آموزش.

RawNet2 ضعیف‌تر از مدل‌های مبتنی بر ویژگی عمل کرد. پردازش مستقیم موج صوتی به آموزش طولانی‌تر و داده بیشتر نیاز دارد.

۳.۷ نتیجه‌گیری

گزاره ۱.۷ > نتیجه کلی

از بین ۱۱ آزمایش موفق، ترکیب LFCC+LCNN با Eval EER برابر ۱۶/۳۹٪ بهترین عملکرد را کسب کرد. سه نتیجه اصلی:

۱. **ویژگی LFCC برتر است:** فیلتربانک خطی با حفظ اطلاعات فرکانس بالا، تشخیص مصنوعات سنتز را تسهیل می‌کند.
۲. **معماری LCNN مؤثر است:** واحد MFM با انتخاب ویژگی ضمنی، عملکرد بهتری نسبت به فعال‌سازی‌های استاندارد ارائه می‌دهد.
۳. **شکاف تعمیم‌پذیری:** اختلاف بزرگ Dev/Eval EER در تمام آزمایش‌ها نشان‌دهنده نیاز به استراتژی‌های مقاوم‌سازی مانند آموزش طولانی‌تر، افزودن متنوع‌تر و روش‌های منظم‌سازی قوی‌تر است.

پیشنهادهای بهبود

- افزایش تعداد دوره‌های آموزش (حداقل ۳۰ دوره با توقف زودهنگام فعال)
- استفاده از افزودن متنوع‌تر (SpecAugment، RIR واقعی)
- بررسی ترکیب ویژگی‌ها (fusion) برای پوشش ضعف‌های هر ویژگی
- آزمایش CQCC با Res2Net و LCNN پس از رفع مشکل ابعاد